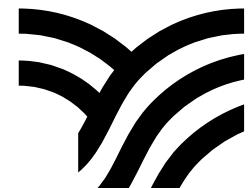


---

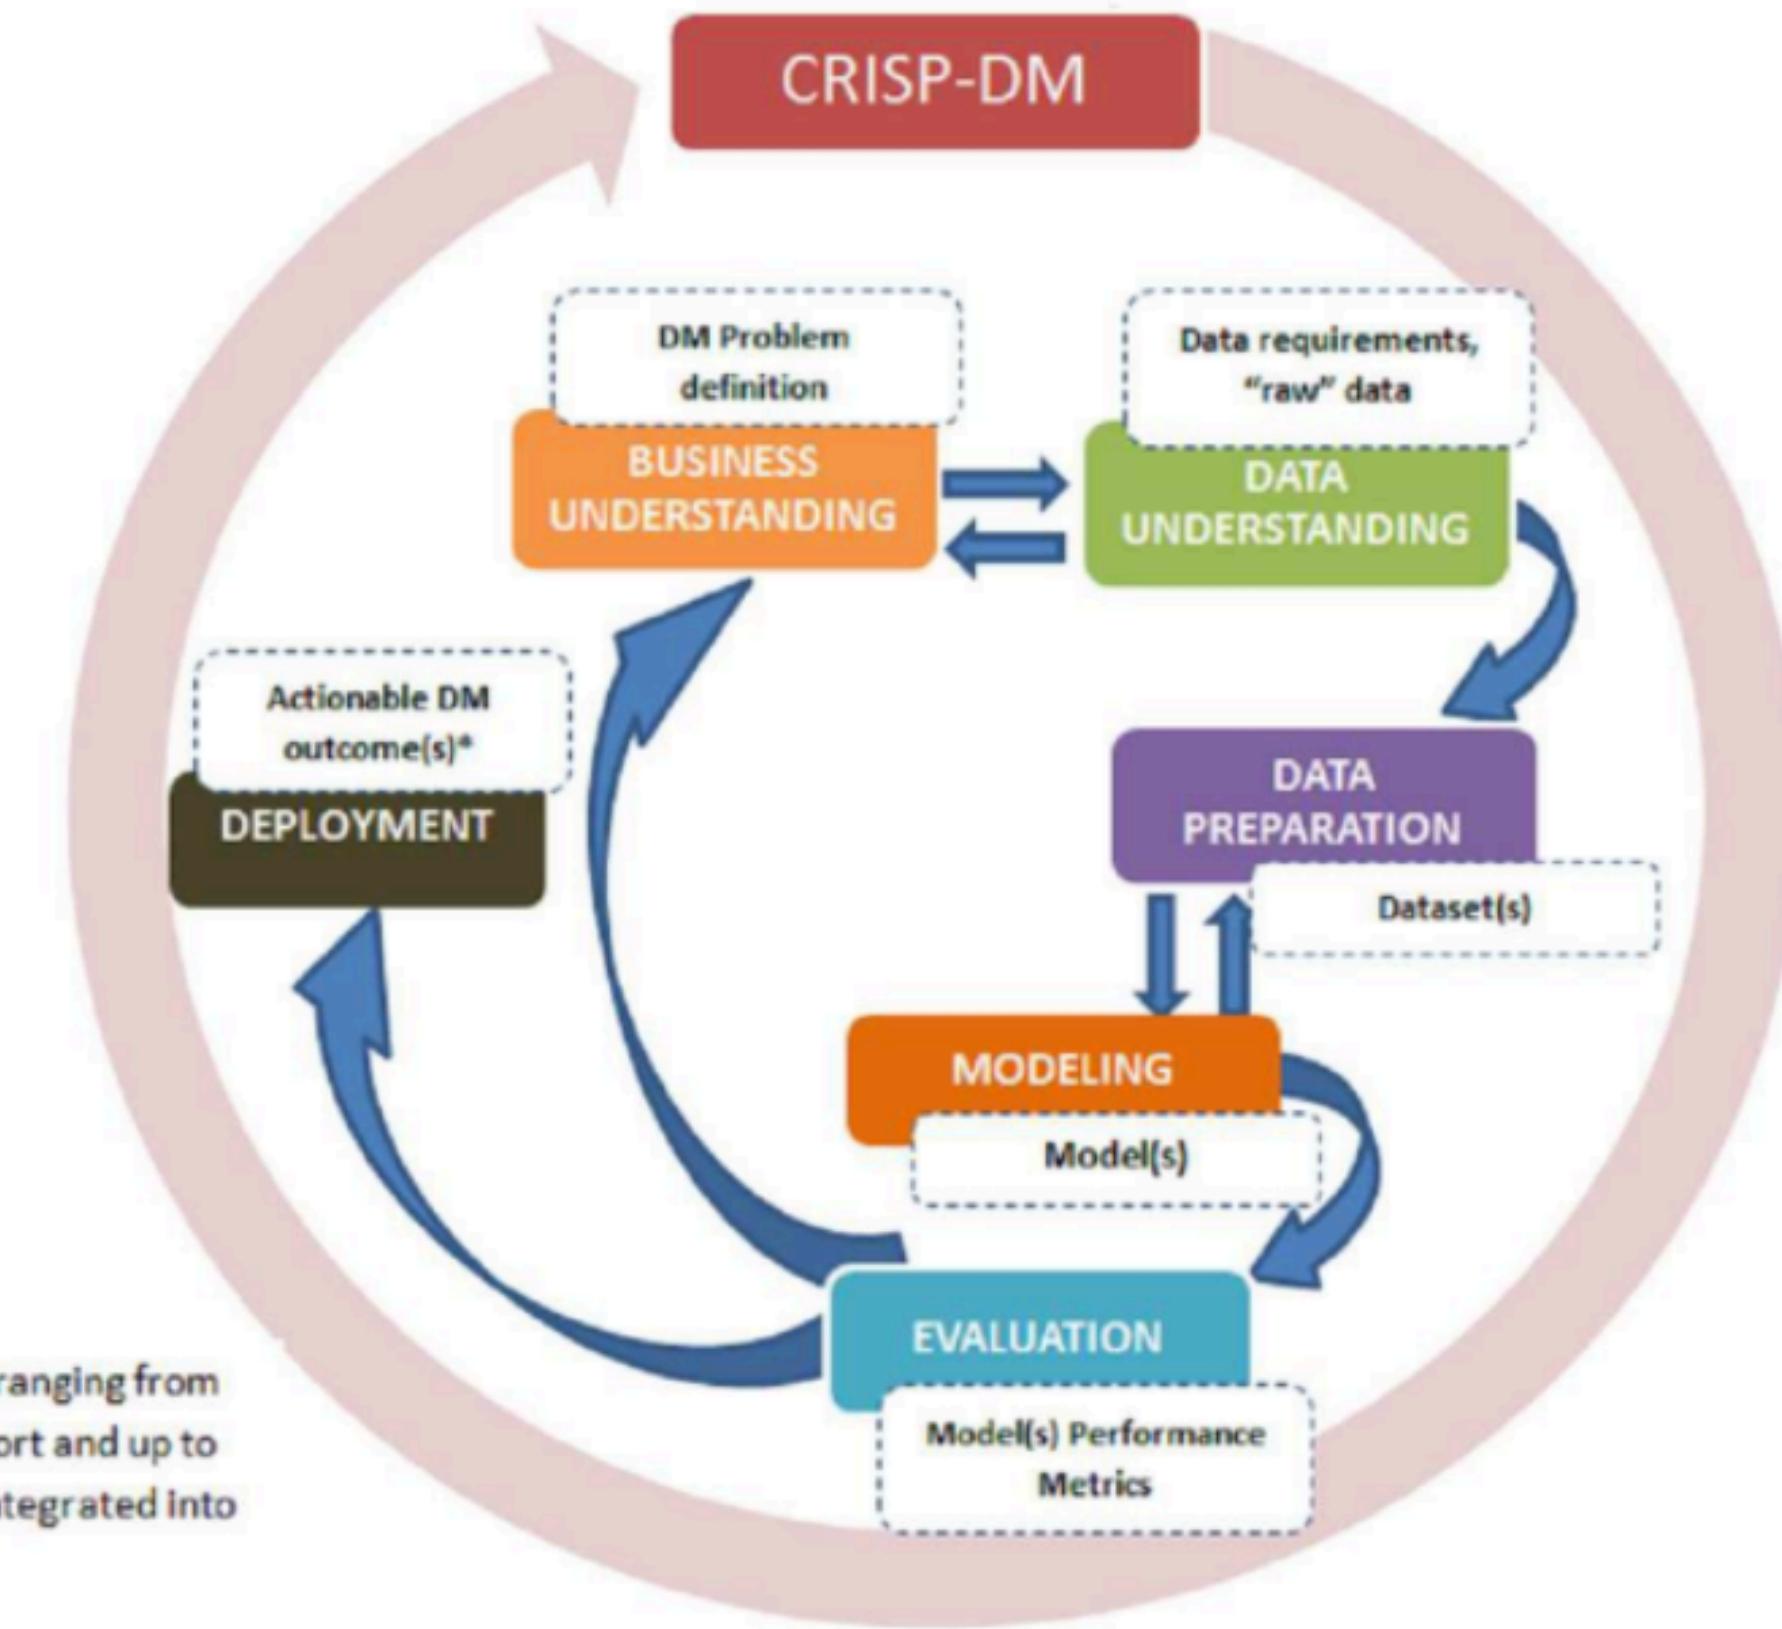
# **Customers Reviews on Businus Hotel, Tunis Analysis**

**Presented By:**



**Ben Amor Hanine  
Cheriaa Nermine  
Logtari Mariem**

Décortiquons cet analyse en se basant sur le modèle CRISP



# Compréhension du métier

## Contexte

- Entité: Le "Business Hotel" (4\*, Tunis – Montplaisir), ciblant une clientèle d'affaires.
- Enjeu: Dans le marché concurrentiel de l'hôtellerie en tunisie, l'hotel doir exploiter l'analyse des retours clients en ligne pour évaluer sa réputation



## Problème Business

- Comprendre la répartition globale des sentiments (Positif vs Négatif) pour prioriser les investissements.



## Objectifs et critères de succès :

- Approche: Appliquer CRISP-DM pour Extraire les données (craping) des plateformes d'avis (Booking, Google Maps). et Analyser les sentiments (Positif, Négatif, Neutre).
- Résultat Attendu: Un modèle de classification fiable (F1-score acceptable) permettant de mesurer la satisfaction globale des clients de l'hotel, les points forts et faibles .

# Aquisition et compréhen — sion des Donées

1. Stratégie de Collecte (Web Scraping)
2. Description du Dataset Final

# Web Scraping

- Choix des sources:  
**Sélection principale de Google Maps (208 avis identifiés) car cette plateforme offre le volume d'avis le plus pertinent contrairement à Momondo (données agrégées) ou Booking.TripAdvisor (accès restreint).**
- Défis & Solutions :  
**Les sites utilisant du contenu dynamique (JavaScript) ont limité l'efficacité de Beautiful Soup. L'approche a donc évolué vers l'utilisation de Selenium (l'extraction de JSON cachés) pour garantir une collecte complète.**  
**D'ailleurs la non -disponibilité des données( restrictions ou sécurisations) n'a pas affecté la variété de nos données car les avis dans Google Maps sont dérivés de plusieurs sites de booking ou d'avis.**

## Description du Dataset Final :

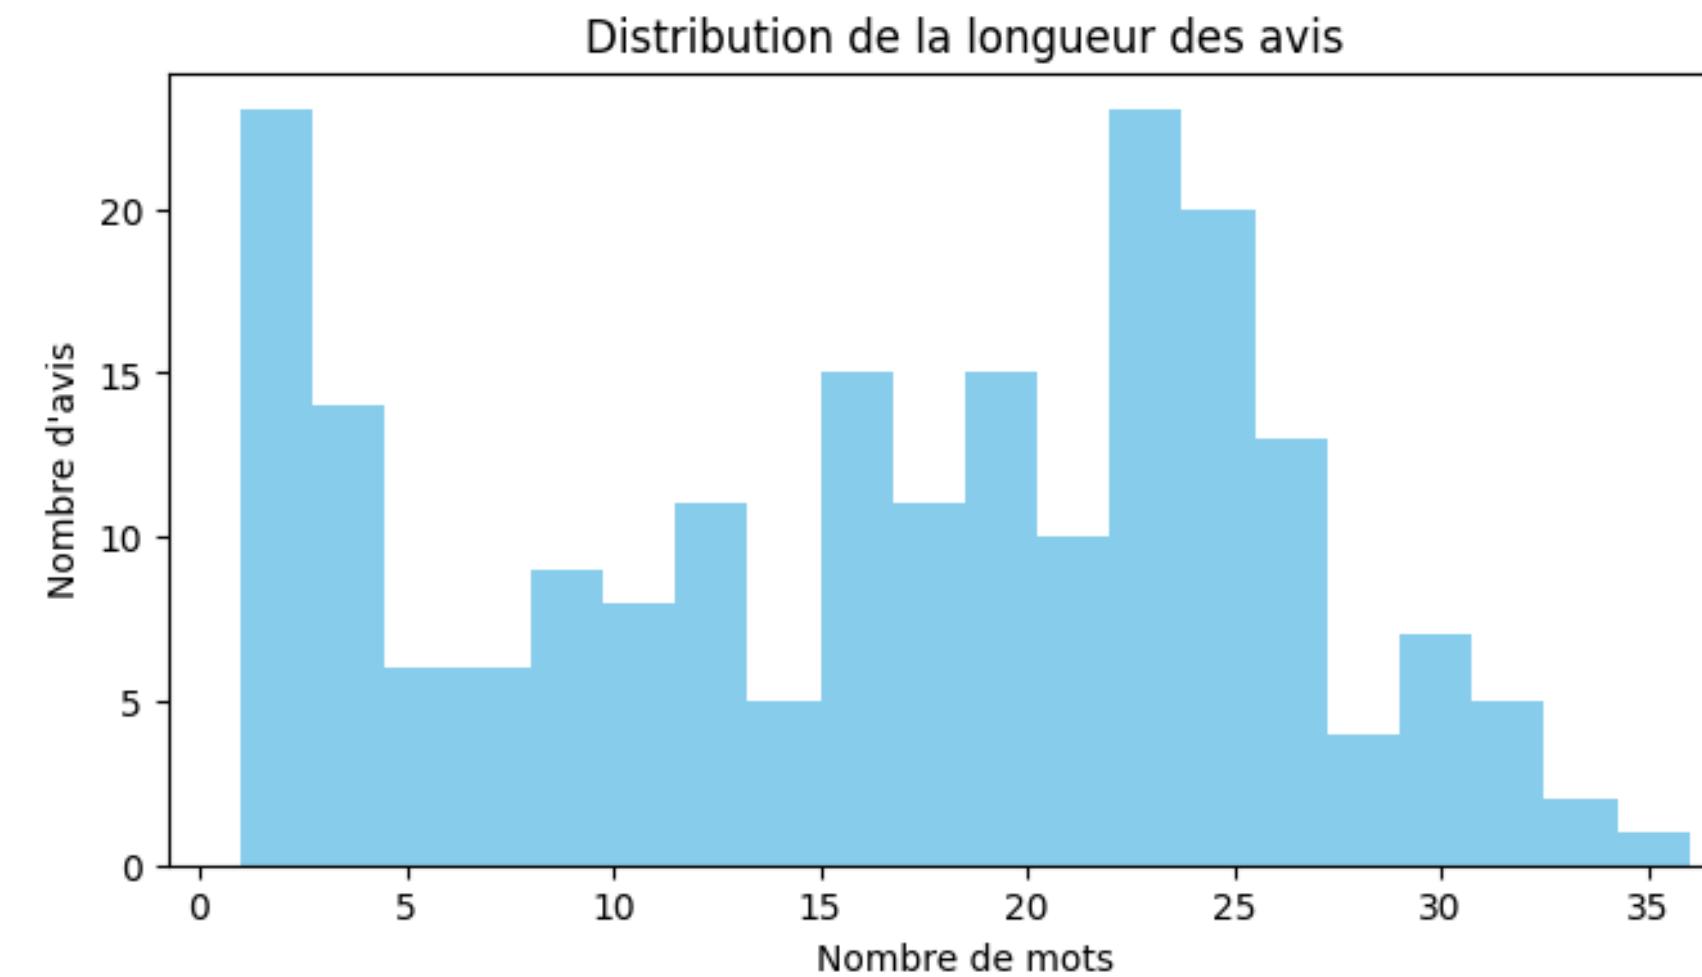
**Volume:** **201 Avis après nettoyage**

**Attributs collectés:** **nom client, Date, Texte après nettoyage**

### Observations:

- **Le jeu de Données manque la note (le rating)==> on a des données non étiquetées. ce qui nous pousse à analyser les sentiments des textes pour pouvoir ajouter ce feature.**

# Exploration du Texte (EDA)



**La distribution est fortement asymétrique à gauche.**

- **La grande majorité des clients laissent des avis très courts (< 30 mots).**
- **Une minorité prend le temps de rédiger des paragraphes détaillé**
- 
- **Cette disparité de longueur confirme la nécessité d'une normalisation (TF-IDF) lors de l'étape suivante,**

# Préparation des Données (Data Preparation )



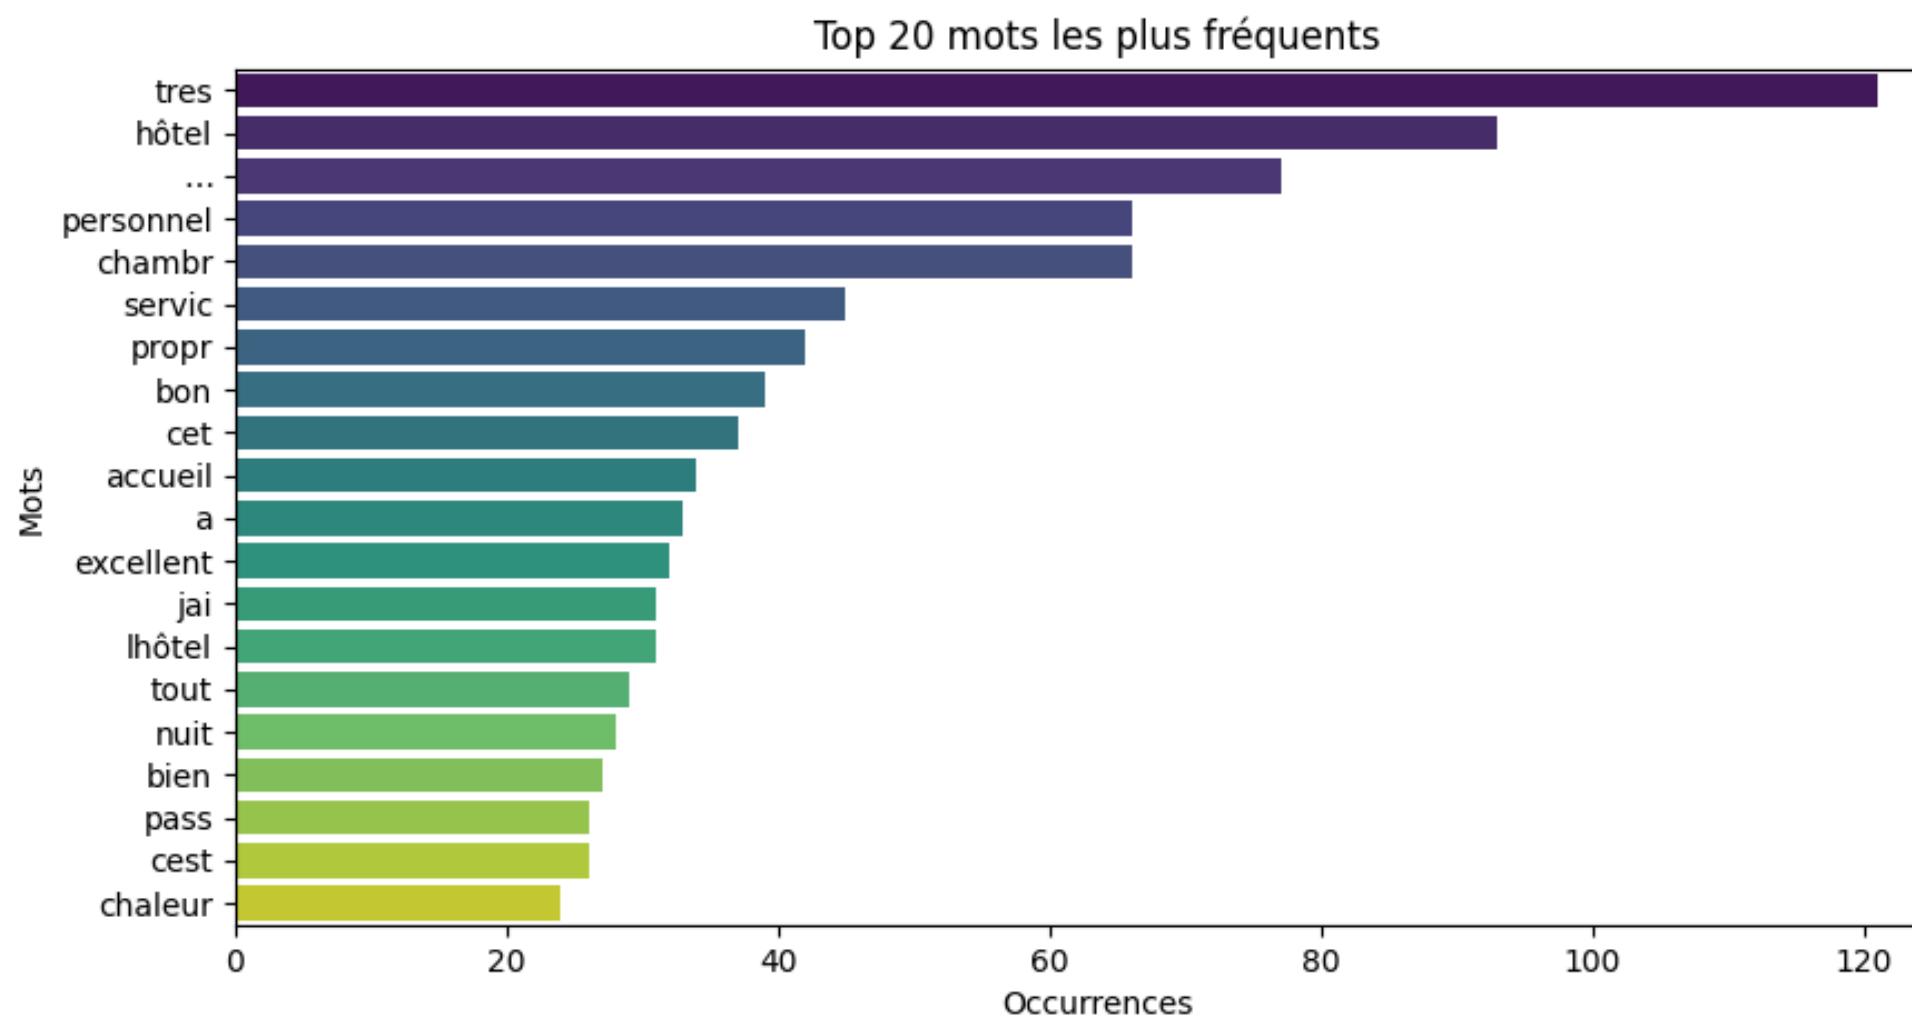
1. Pipeline de Nettoyage NLP (Text Cleaning)
2. Crédit de la Variable Cible (Labeling)
3. Vectorisation (Feature Extraction)

# Pipeline de Nettoyage NLP (Text Cleaning)

→ objectif: Transformer les commentaires bruts et bruyants en texte propre exploitable.

Traitements appliqués :

- Normalisation : Conversion en minuscules.
- Nettoyage : Suppression de la ponctuation, caractères spéciaux et chiffres.
- Filtrage : Retrait des Stopwords via NLTK.
- Racinisation (Stemming) : Réduction des mots à leur racine avec SnowballStemmer



- Validation du Nettoyage : L'élimination des stopwords et le stemming font émerger les thèmes clés de l'hôtellerie ("Chambre", "Personnel", "service", "acceuil").  
==> Le bruit a été filtré avec succès.
- On voit des mots de sentiments, très, bon excellent, propore

# Vectorisation (Feature Extraction)

## 1. Construction du Vocabulaire (Bag-of-Words):

**Matrice résultante: de dimension 201 x 1005:**

- 201 lignes (Avis clients).
  - 1005 colonnes (Le vocabulaire unique appris).

# C'est notre espace de travail

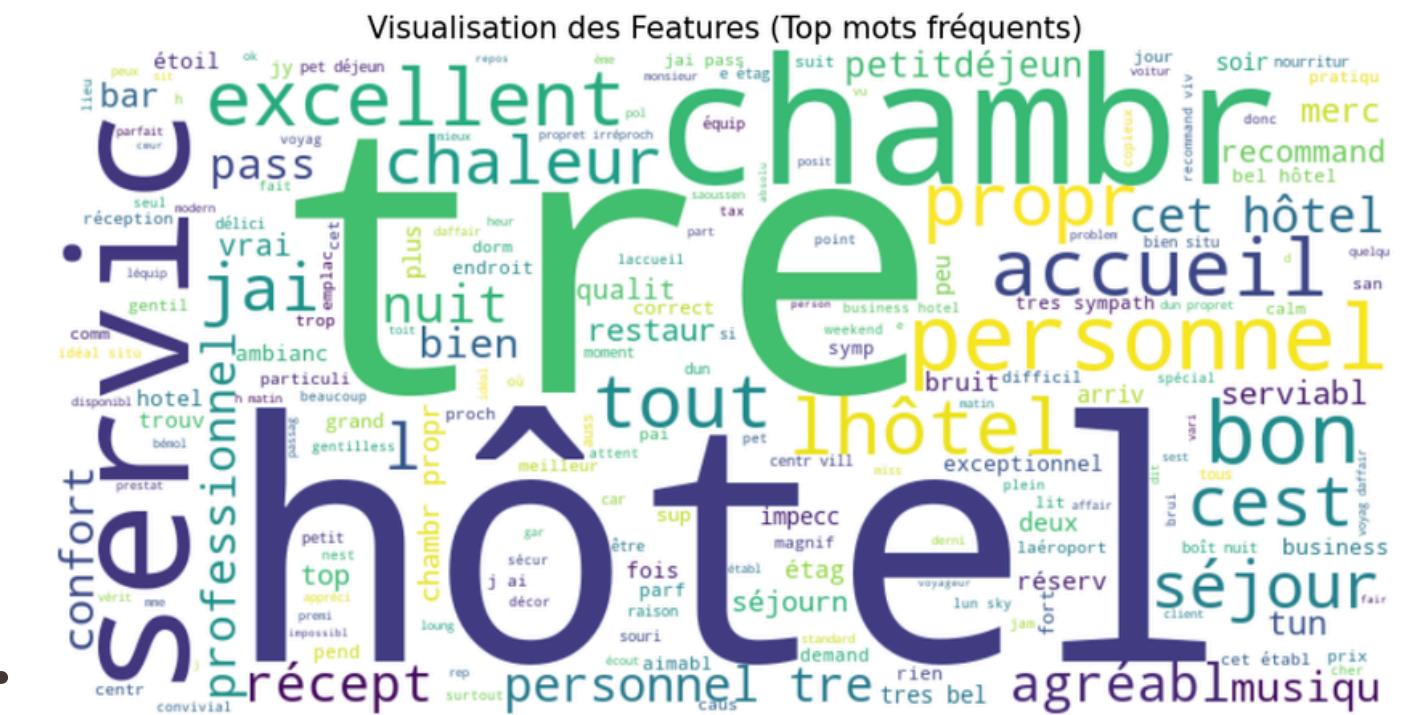
## → 2. Vectorisation

# Méthode : Utilisation de TF-IDF (Term Frequency-Inverse Document Frequency).

# Objectif: Pondérer selon la rarité statistique.

**Résultat: réduire le poids des mots trop fréquents et de valoriser les termes spécifiques qui portent du sens.**

-> éliminer le bruit fréquentiel



# Nuage de Mots:

**En analysant la fréquence brute (Bag-of-Words), on voit que des termes génériques écrasent tout le reste.**

**Mais ne donnent aucune indication sur la satisfaction du client**

**C'est pour corriger ce défaut visuel que nous passons ensuite au TF-IDF**

## → Matrice finale : dimension de 201\*1005 pondérée

# Génération des Labels & Analyse de Sentiment

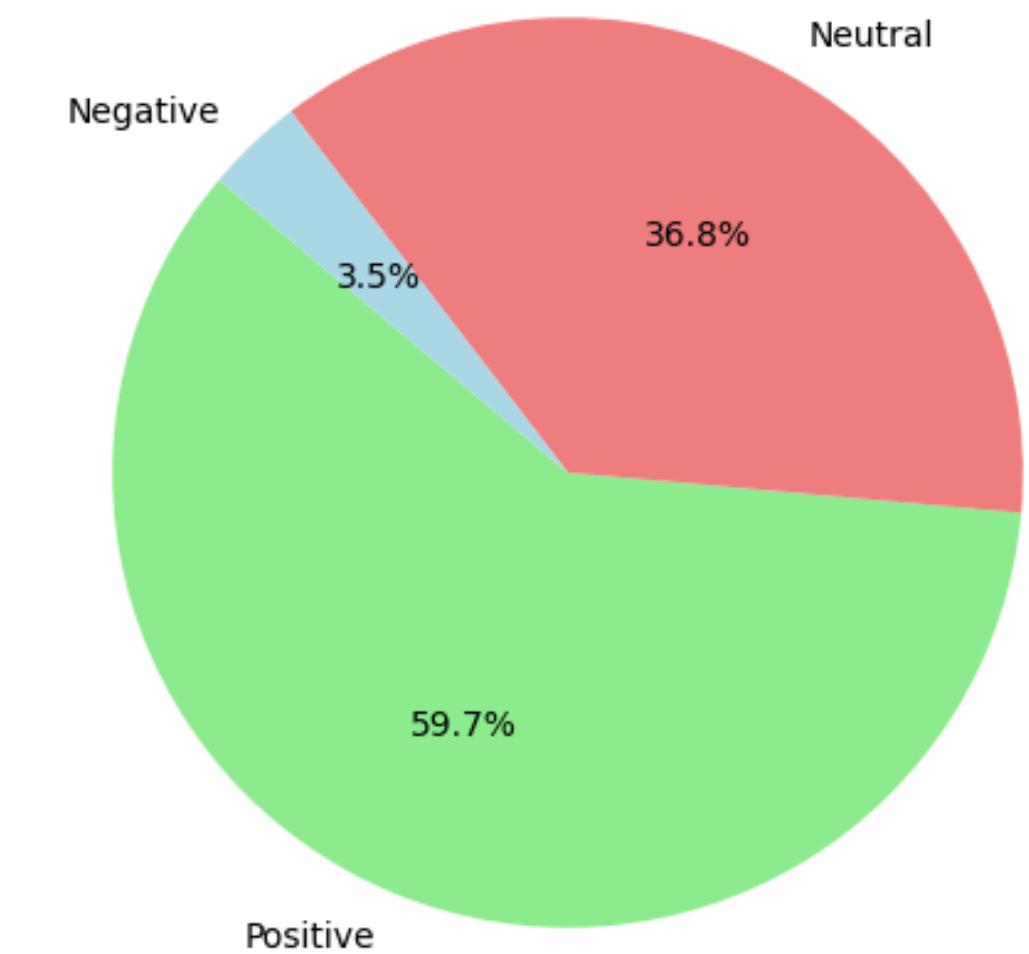
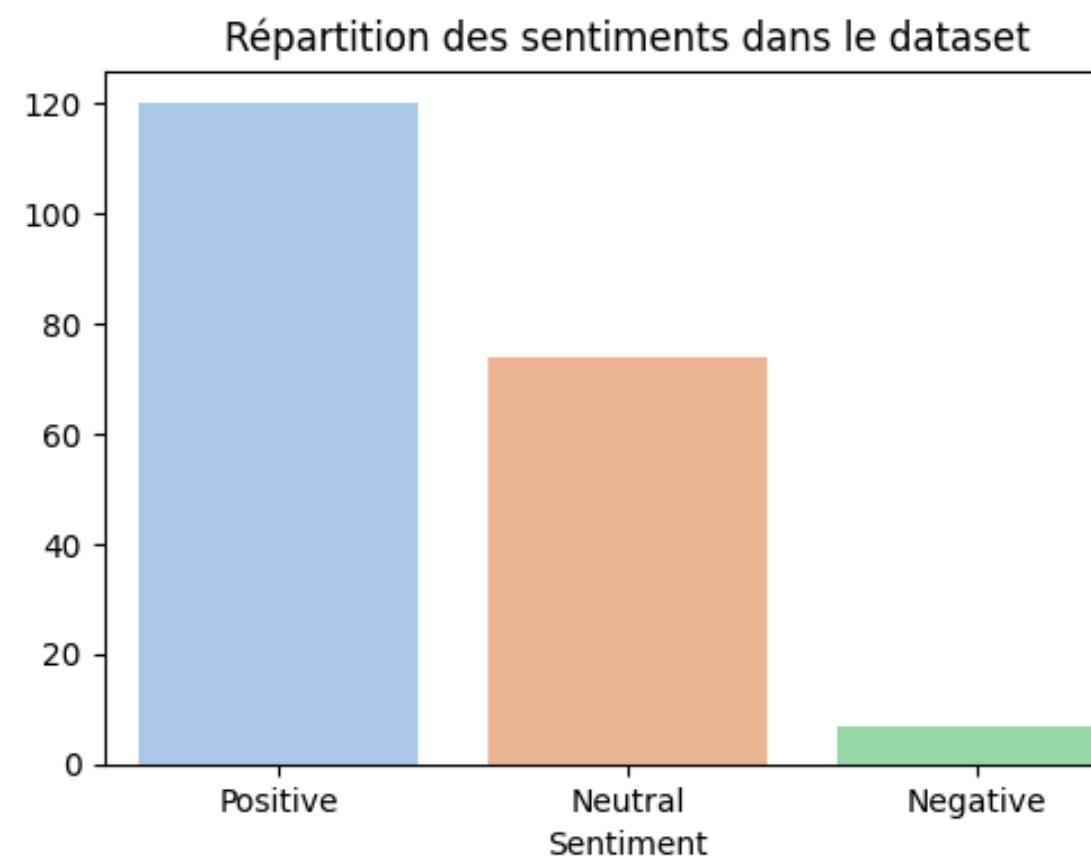
## → Ground Truth

- Les données scrapées contiennent le texte mais pas de note (Rating) exploitable.
- Conséquence : Nous sommes dans un cas non supervisé, mais nous avons besoin de classes pour entraîner un classifieur.

Répartition globale des sentiments

## → Solution : Labellisation Automatique

- Outil : Utilisation de TextBlob-FR (Approche Lexicale)
- Pas robuste mais suffisante pour un mini projet ).
- Méthode : Calcul d'un score de polarité pour chaque avis (basé sur un dictionnaire de mots positifs/négatifs).
- Règle de décision :
  - Polarité  $>0.1 \rightarrow$  Positif
  - Polarité  $<0.1 \rightarrow$  Négatif
  - Polarité = Neutre



Cette distribution reflète une bonne satisfaction client (Business), mais crée un déséquilibre extrême (Data Science) la phase du training qui rendra la détection des avis négatifs très difficile

# Environnement & Stratégie de Modélisation

Objectif

Construire un modèle de classification supervisée permettant de prédire le sentiment d'un avis client (Positive / Neutral / Negative).

## Environnement & Outils

- Python 3.10 – langage principal
- Conda – gestion des environnements
- Jupyter Notebook – expérimentation

## Libraries / Packages

- scikit-learn: vectorisation + algorithmes
- imbalanced-learn: oversampling
- pandas/ numpy – manipulation des données
- textblob/NLTK: Prétraitement NLP.
- joblib – sauvegarde du modèle

## Sélection des Algorithmes

Nous avons mis en compétition trois algorithmes:

- Multinomial Naive Bayes : La "baseline" pour les données textuelles et petites, rapide et probabiliste.
- Logistic Regression : Simple, interprétable, robuste pour la classification binaire.
- SVM Linéaire: efficace sur données haute dimension (TF-IDF), souvent meilleur sur texte

## Méthode d'Entraînement

Cross-Validation (Validation Croisée) :

Pour éviter le hasard d'une seule découpe (Train/Test) -> nous validons la robustesse du modèle sur 5 plis (K-Fold = 5)

```
==== Logistic Regression ====
Accuracy scores: [0.63414634 0.7           0.675      0.675      0.65      ]
Mean accuracy: 0.6668292682926829

==== Multinomial Naive Bayes ====
Accuracy scores: [0.58536585 0.65        0.65       0.625      0.6       ]
Mean accuracy: 0.6220731707317073

==== SVM (Linear) ====
Accuracy scores: [0.70731707 0.725      0.65       0.65      0.675      ]
Mean accuracy: 0.6814634146341463

Meilleur modèle : SVM (Linear) avec accuracy moyenne = 0.6815
```

Tableau comparatif des performances (Cross-Validation 5-fold)  
accuracy sur chaque Fold

## Pourquoi le SVM a gagné ?

Le SVM est mathématiquement le plus performant pour gérer les espaces de haute dimension (nos 1005 features TF-IDF) même avec peu de données.

---

# **Évaluation de la Performance & Résultats**



**Le Piège de l'Accuracy:** Avec 97% de données positives/neutres, l'Accuracy est un indicateur trompeur.

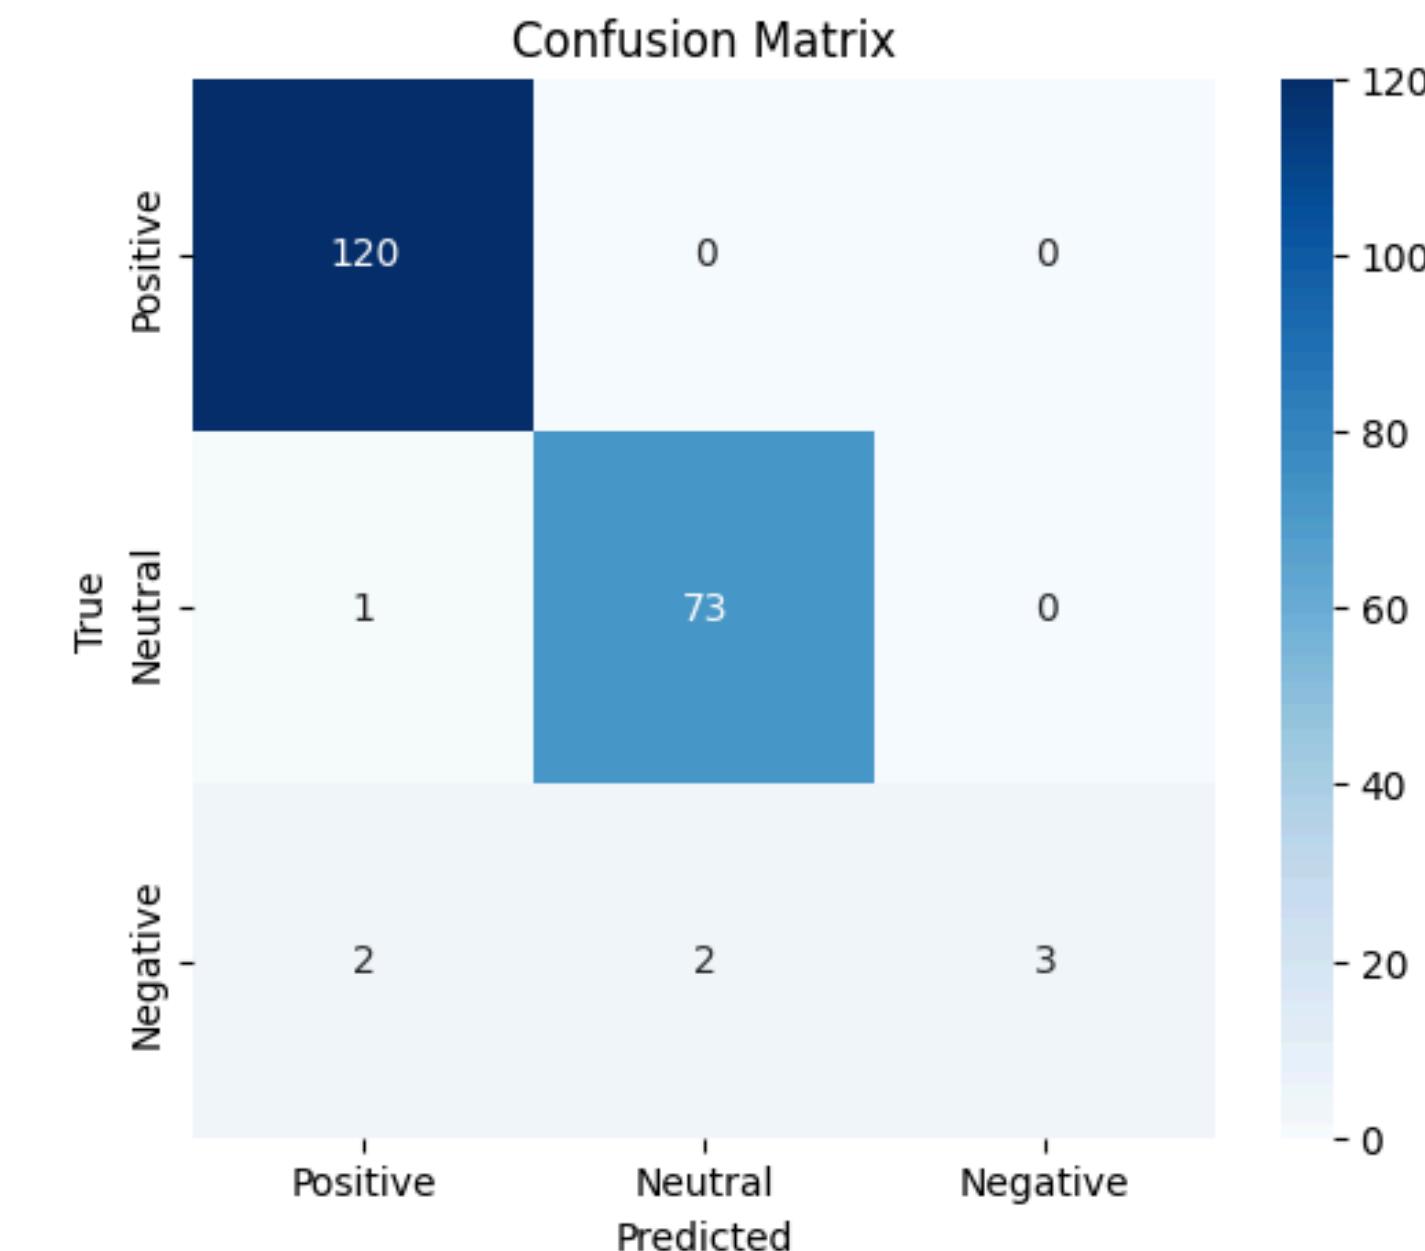
**Notre Choix : F1-Score Pondéré (Weighted):** C'est la moyenne harmonique de la **Précision** (qualité) et du **Rappel** (quantité).

```
f1 = f1_score(y, y_pred, average='weighted')  
#weighted F1 pour prendre en compte  
déséquilibre éventuel
```

→ **Le modèle a parfaitement assimilé les données d'entraînement (Accuracy > 97%).**

**La pondération (Weighted F1) confirme une bonne gestion globale des classes.**

**Note critique :** Cette performance très élevée s'explique par la taille réduite du **corpus (201 avis)** et la forte prédominance des avis positifs. Le modèle est "expert" sur ce dataset spécifique.



**Accuracy (tout dataset): 0.9751**  
**F1-score (weighted): 0.9713**

# Problèmes et améliorations

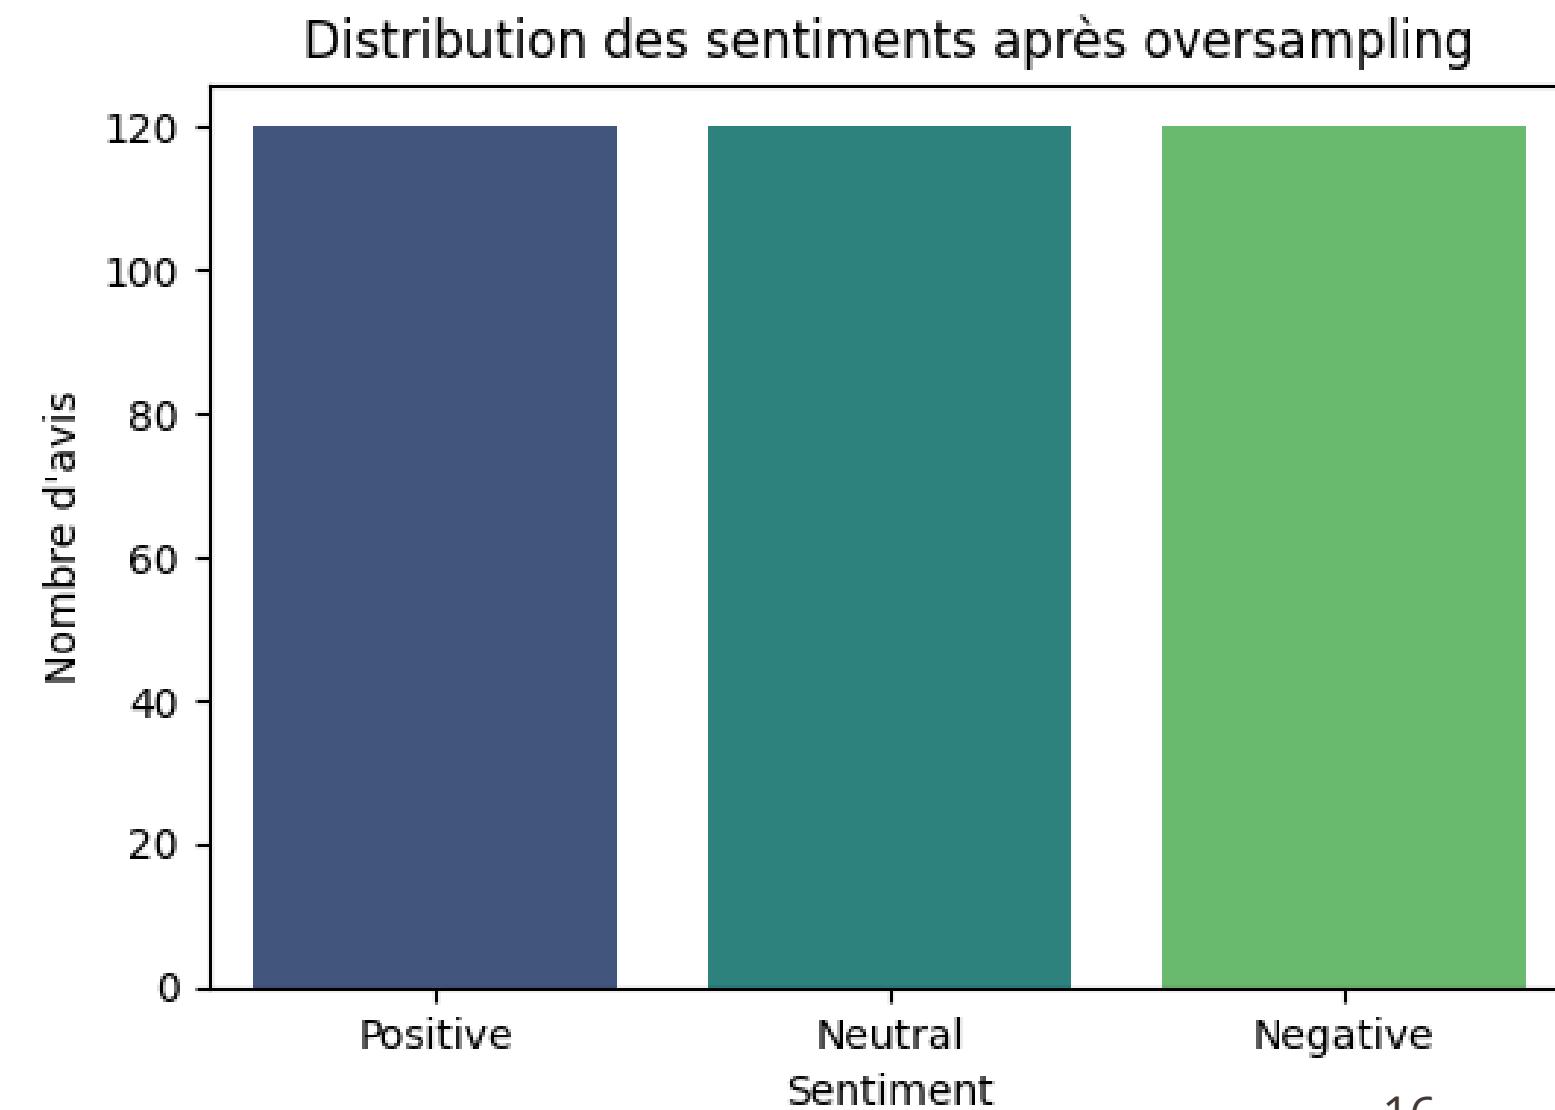
## → Le Diagnostic : Déséquilibre Critique

- **Réalité des Données** : Une disproportion majeure entre la satisfaction (120 avis positifs) et le mécontentement (7 avis négatifs).
- **Le Piège de l'Accuracy** : Avec les données brutes, un modèle "naïf" atteint 97% d'exactitude... simplement en prédisant "Positif" tout le temps. Le modèle naïf maximise l'Accuracy globale au détriment du Rappel (Recall) de la classe minoritaire.
- **Conséquence** : Incapacité totale à détecter la classe "Négative" (Recall ~ 0).
- **Impact Métier** : Rater une plainte critique (Faux Négatif) coûte beaucoup plus cher à la réputation de l'hôtel que de rater un compliment: pour l'hôtel, détecter un client mécontent est l'objectif prioritaire.

**Stratégie d'Amélioration: SMOTE (Oversampling)**  
**SMOTE= Synthetic Minority Over-sampling Technique**

- Principe : L'algorithme crée des exemples synthétiques (artificiels) en mélangeant les caractéristiques des avis négatifs existants via la librairie imbalanced-learn.
- Action : Il gonfle le nombre d'avis négatifs dans le jeu d'entraînement jusqu'à ce qu'il y en ait autant que les positifs

→ Le problème de biais est techniquement résolu.



# Impact du Rééquilibrage (Résultats Post-SMOTE)

→ Le SVM est encore gagant

Performance:

Métrique : Moyenne sur 5 tests (K-Fold).

Score SVM : 90.00% (0.9000).

Évolution : On passe de ~68% (avant SMOTE) à 90%.

Le modèle est devenu très robuste.

## Performance sur le Dataset Complet

- Accuracy : 99.44%
- F1-Score (Weighted) : 99.44%
- Focus Classe "Négative":
  - Précision : 1.00
  - Rappel (Recall) : 1.00
- Interprétation : Le modèle ne rate plus aucun avis négatif dans ce jeu de données.



# Deployment



## Test en Temps Réel

Nous avons soumis au modèle des avis inédits pour valider sa compréhension des concepts clés.

Review: Un personnel excellent et très accueillant

Predicted sentiment: Positive

Review: il est situé au centre ville de Tunis.

Predicted sentiment: Neutral

Review: cher, chambre bruitée , tres deconseillée.

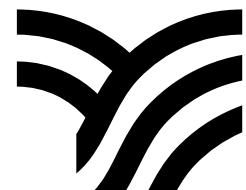
Predicted sentiment: Negative



Détection correcte des termes valorisants

Identification du contenu factuel et non-émotionnel

Reaction aux mots clés avec succès



## Note: Limites & Améliorations Futures

### **Les Freins Actuels**

Données : Volume critique (201 avis) + Bruit dans les labels (TextBlob).

Technique : Le SVM (TF-IDF) ignore le contexte (ironie, double négation)

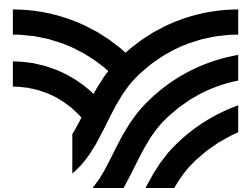
### **Les Solutions Futures**

Industrialisation : Scraper 2000+ avis pour combler les trous de vocabulaire.

Intelligence : Passer au Deep Learning (CamemBERT par exemple) pour comprendre les nuances et faire du NLP robuste.

### **Topic Modeling : Clustering Non-Supervisé**

Utiliser des algorithmes (type LDA ou K-Means) pour grouper automatiquement les avis par sujets dominants : Propreté, Service, Restauration, Isolation.=> Identifier précisément les causes de satisfaction ou de plainte, au-delà du simple score positif/négatif.



-

MERCI !

